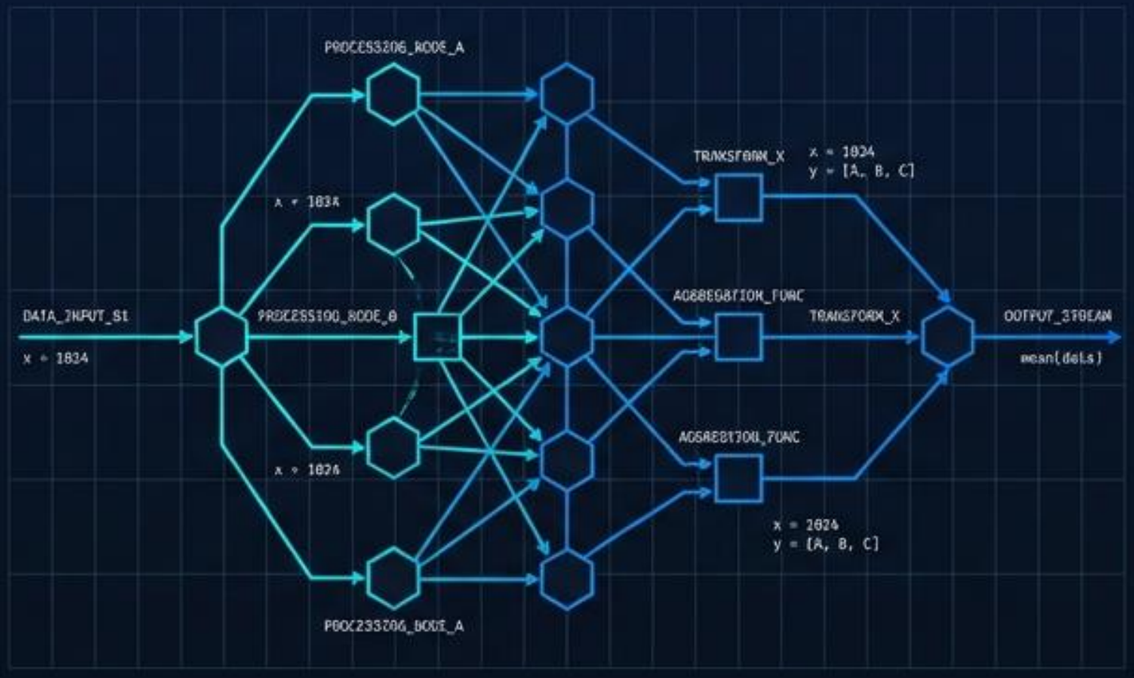

Pandas 활용 데이터 처리 및 연산

핵심 통계 함수 마스터하기 (Mean, Median, Min, Max)

IT Tech Conference 2024

학습 목표

1. 대푯값 산출: 평균값, 중간값, 최솟값, 최댓값 도출

2. 산포도 이해: 표준편차, 분산, 공분산 도출

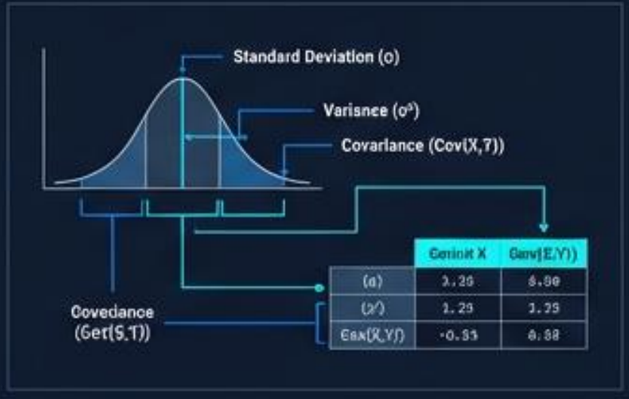

3. 관계성 파악: 두 열 간의 상관계수 도출

핵심 학습 내용

Pandas

1. 평균값, 중간값, 최솟값, 최댓값 익히기
2. 표준편차, 분산, 공분산 익히기
3. 상관계수 익히기

통계 함수 개요

[중심경향치] 자료 전체의 대표값
(평균값, 중앙값, 최빈값)

[극단값/범위] 데이터의 경계 파악
(최솟값, 최댓값)

[특징] 문자열 및 문자 데이터 자동 무시 후 연산 수행

평균값 (Mean) 개념

- **[정의]** 데이터 총합을 총 개수로 나눈 값
- **[특징 1]** 극단적인 값(Outlier)의 영향에 취약
- **[특징 2]** 비대칭 분포 데이터의 경우 전체 대표성 하락
- **[함수명]** mean

$$\sum \frac{\Sigma}{n}$$

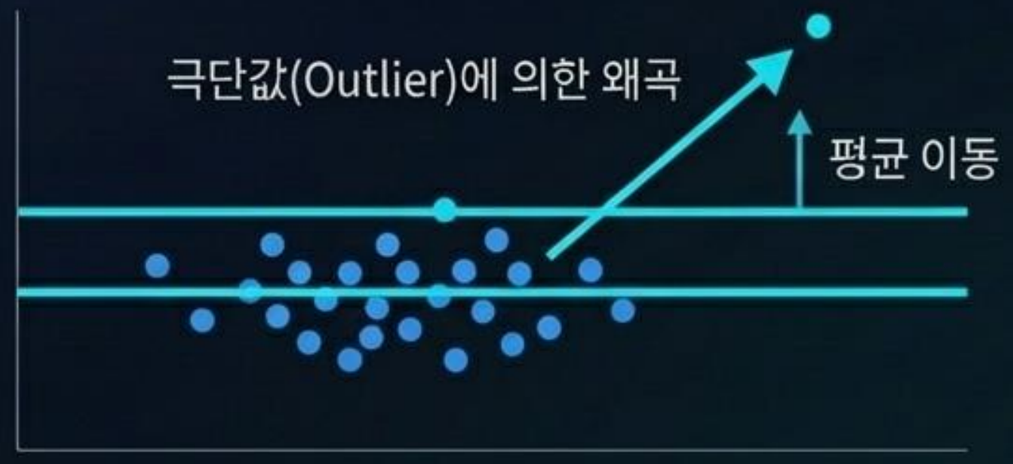

평균값 함수 구조

[명령어]

```
DataFrame.mean(axis=None, skipna=None)
```

[axis 파라미터]
0: 행 기준 연산 (기본값) / **1**: 열 기준 연산
1: 열 기준 연산

[skipna 파라미터]
True: NaN/Null 제외 (기본값) /
False: NaN 포함 연산

평균값 산출 (기본값)

[조건] skipna=True, axis=0 (기본 설정 적용)

Input

```
import pandas as pd

df = pd.DataFrame({'X': [1, 2, None, 3],
                   'Y': [4, 3, 8, 4]})

df.mean()
```

Output

```
X     2.00
Y     4.75
dtype: float64
```

평균값 산출 (결측치 포함)

[조건] skipna=False 적용 시 연산 결과

Input

```
import pandas as pd

df = pd.DataFrame({'X': [1, 2, None, 3],
                   'Y': [4, 3, 8, 4]})

df.mean(skipna=False)
```

Output

```
X      NaN
Y     4.75
dtype: float64
```

(결측치 연산 불가)

평균값 산출 (열 기준 연산)

[조건] axis=1 적용 (행을 따라 각 열의 평균 산출)

Input

```
import pandas as pd

df = pd.DataFrame({'X': [1, 2, None, 3],
                   'Y': [4, 3, 8, 4]})

df.mean(axis=1)
```

Output

```
0    2.5
1    2.5
2    8.0
3    3.5
dtype: float64
```

중간값 (Median) 개념

- [정의] 크기순 정렬 시 가장 중앙에 위치하는 값
- [특징 1] 상위 50%와 하위 50%를 가르는 기준점
- [특징 2] 총 데이터 수가 짝수일 경우 중앙 2개 값의 평균 산출
- [함수명] `median`

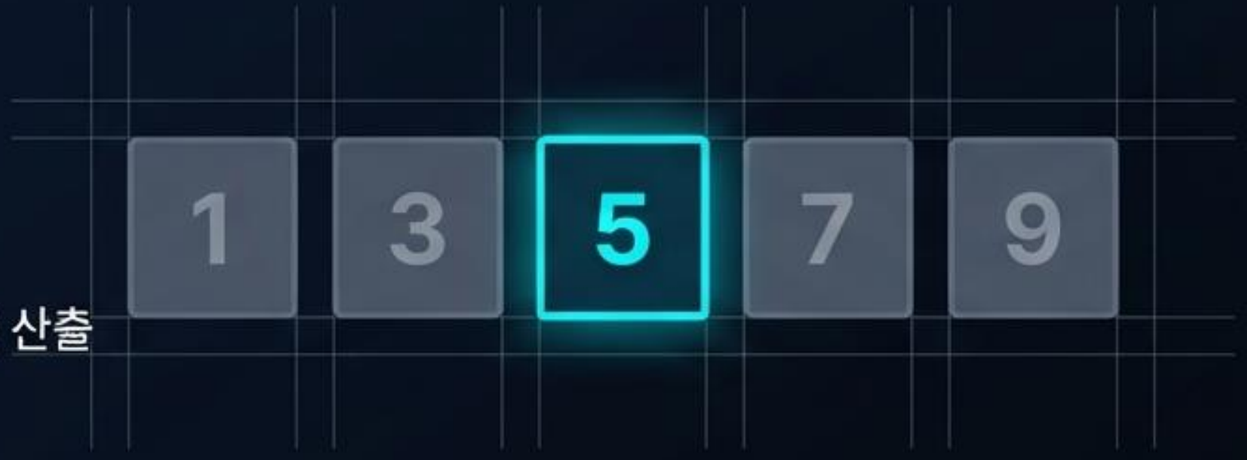

중간값 함수 구조

[명령어]

```
DataFrame.median(axis=None, skipna=None)
```

[axis 파라미터]
0: 행 방향 (기본값) / 1: 열 방향

[skipna 파라미터]
True: NaN 제외 (기본값) /
False: NaN 포함

중간값 산출

[조건] df.median() 실행 (NaN 자동 제외)

Input

```
import pandas as pd

df = pd.DataFrame({'X': [1, 2, None, 3],
                   'Y': [4, 3, 8, 4]})

df.median()
```

Output

```
X    2.0
Y    4.0
dtype: float64
```

최빈값 (Mode) 개념

[정의] 가장 빈번하게 관찰 및 측정되는 값

[적용] 주로 범주형 변수 (명명척도, 서열척도)에 활용

[함수명] `mode`

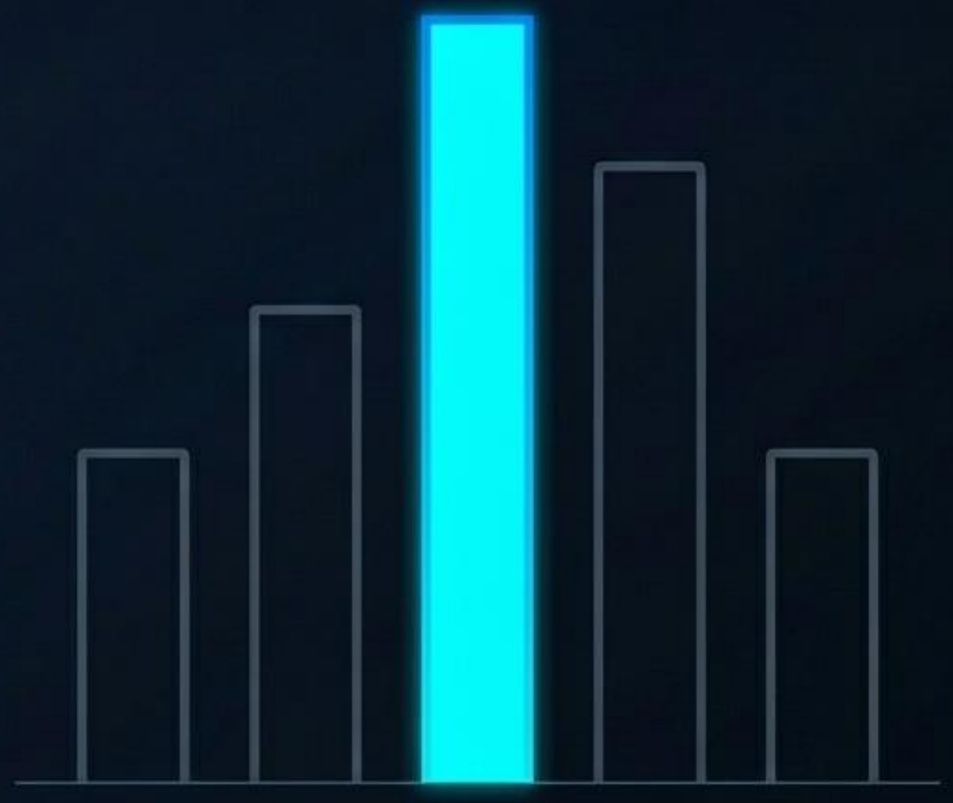

최솟값 (Min) 개념

- [정의] 전체 데이터 중 가장 작은 값 산출
- [특징] 특정 열 선택 계산 가능, 문자 데이터 무시
- [함수명] `min`
- [참고] `idxmin`: 최솟값을 가지는 인덱스 레이블 추출

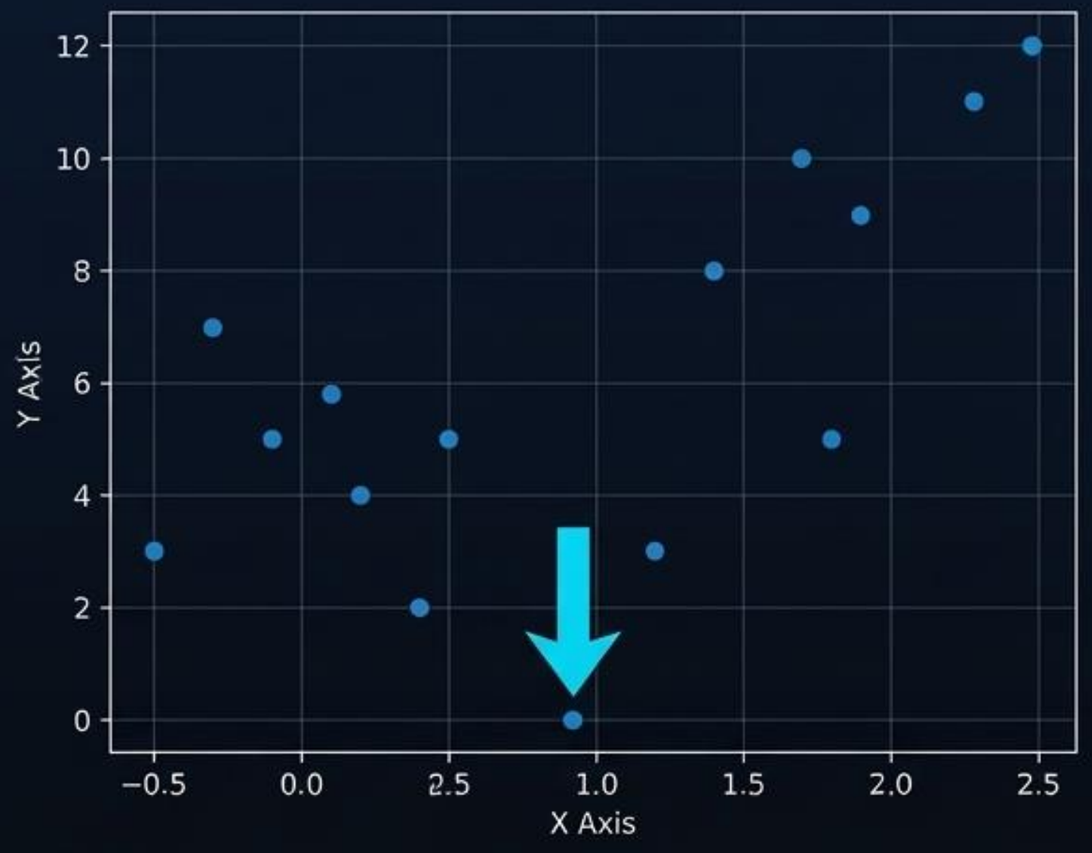

핵심 통계 함수 요약 (Summary Matrix)

함수명	분류	NaN 기본처리	주요 특징
mean()	중심경향치	skipna=True (제외)	극단값(Outlier)에 취약
median()	중심경향치	skipna=True (제외)	상/하위 50% 분기점 위치
mode()	중심경향치	skipna=True (제외)	범주형 데이터 활용 최적화
min()	극단값	skipna=True (제외)	최소치 파악, idxmin 연계
max()	극단값	skipna=True (제외)	최대치 파악, idxmax 연계

Pandas DataFrame 통계 함수

산포도(Dispersion) 및 상관관계(Correlation) 분석

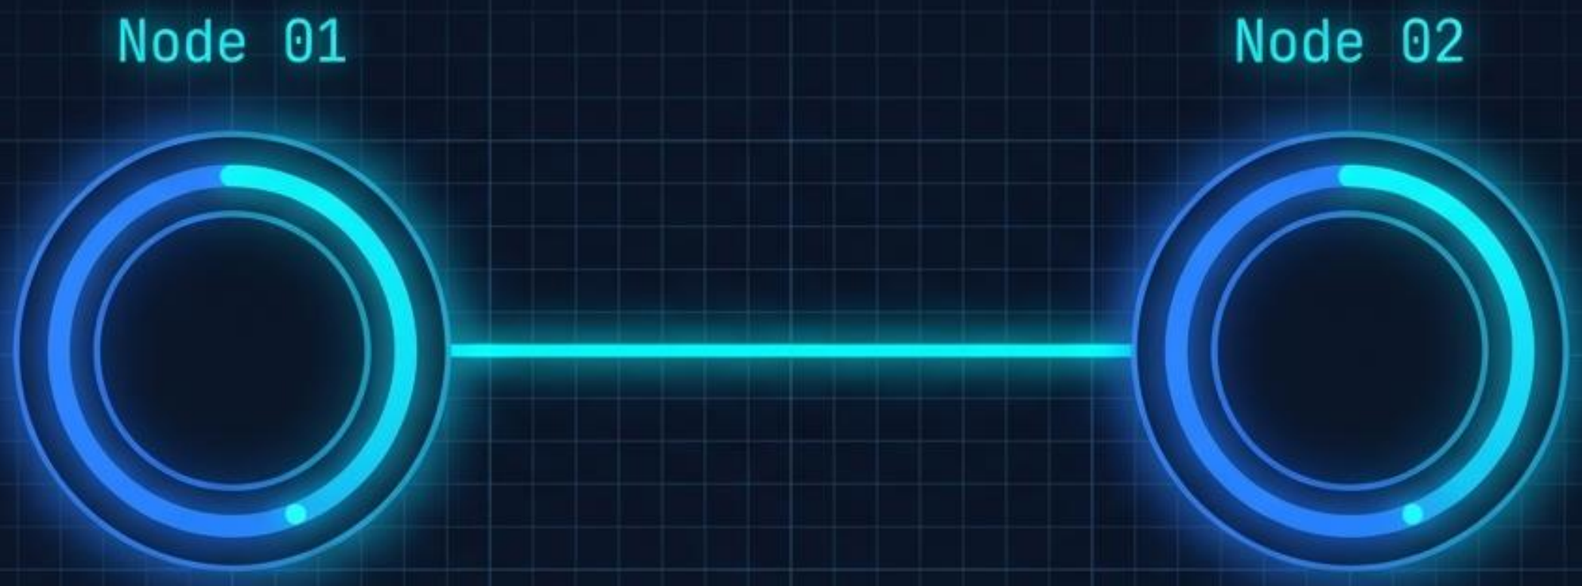

표준편차, 분산, 공분산

데이터의 산포도 및 변수 간 기본 관계
측정 지표 학습

상관계수 (Correlation Coefficient)

피어슨(Pearson), 스피어만(Spearman),
켄달(Kendall) 상관계수 개념 및 구현

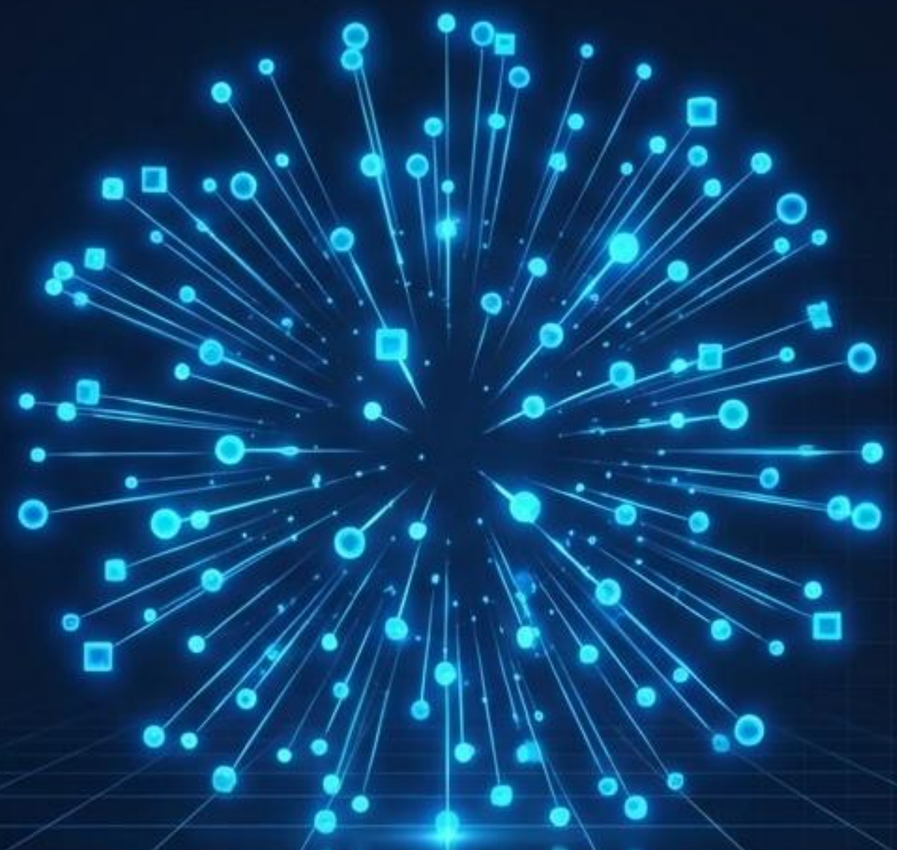

01

표준편차, 분산, 공분산

Key Focus: 데이터의 흩어짐과 방향성 이해

Low Std Dev

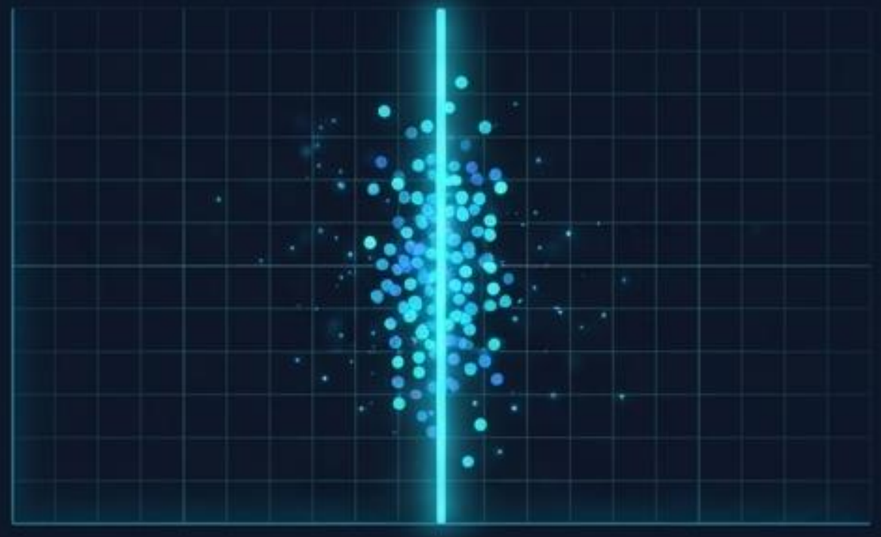

High Std Dev

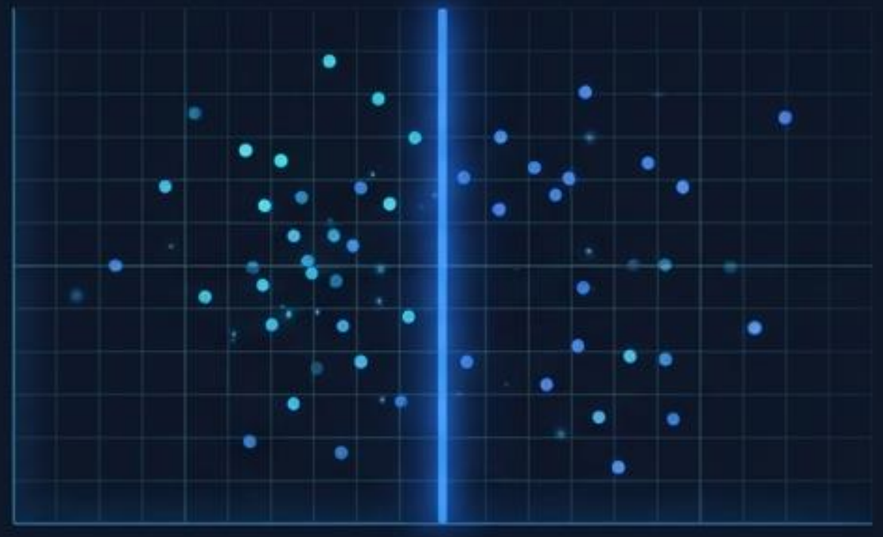

표준편차 (Standard Deviation)

- 자료가 평균을 중심으로 얼마나 퍼져 있는지를 나타내는 대표적인 수치임
- 각 데이터가 평균에서 얼마나 벗어나는지를 측정함
- 0에 가까울수록 데이터가 평균 근처에 집중되어 있음을 의미함
- 값이 클수록 데이터가 넓게 분포되어 있음을 의미함

```
>_ Pandas Keyword: std
```

분산 (Variance)

- 값들이 흩어진 정도를 계산하는 핵심 지표임
- 데이터와 평균 간의 차이를 '제곱'하여 산출함
- 표준편차와 함께 데이터의 산포도를 평가하는 데 사용됨

Pandas Keyword: **var**

>_ Pandas Keyword: **cov**

공분산 (Covariance)

- 두 변수 간의 상관 정도를 나타내는 수치임
- 공분산이 양수(+)인 경우, 두 변수가 함께 상승하는 경향을 보임
- 변수 간의 방향성을 파악하는 데 유용함

```
DataFrame.std(axis=None, skipna=None)
```

axis

행(0) 또는 열(1)을 기준으로
표준편편차 계산 방향 설정

skipna

결측치(NA/null) 제외 여부 설정
기본값: True

데이터 준비 및 실행

- X 열: [1, 2, None, 3]
- Y 열: [4, 3, 8, 4]

```python
import pandas as pd
df=pd.DataFrame({'X': [1, 2, None, 3],
                 'Y': [4, 3, 8, 4]})
df.std()
```

```
X    1.000000
Y    2.217356
dtype: float64
```

결과 분석:

- X 열 표준편차: 1.000000 산출됨
- Y 열 표준편차: 2.217356 산출됨

```
DataFrame.var(axis=None, skipna=None)
```

axis: 기준 축 설정 (기본값: 0)

skipna: 결측치 처리 (기본값: True)

```
import pandas as pd
df=pd.DataFrame({'X': [1, 2, None, 3],
                 'Y': [4, 3, 8, 4]})
df.var()
```

```
X     1.000000
Y     4.916667
dtype: float64
```

```
DataFrame.cov()
```

- X와 Y 간 공분산: 0.000000 (독립적 성향)

```
import pandas as pd
df=pd.DataFrame({'X': [1, 2, None, 3],
                 'Y': [4, 3, 8, 4]})
df.cov()
```

	X	Y
X	1.0	0.000000
Y	0.0	4.916667

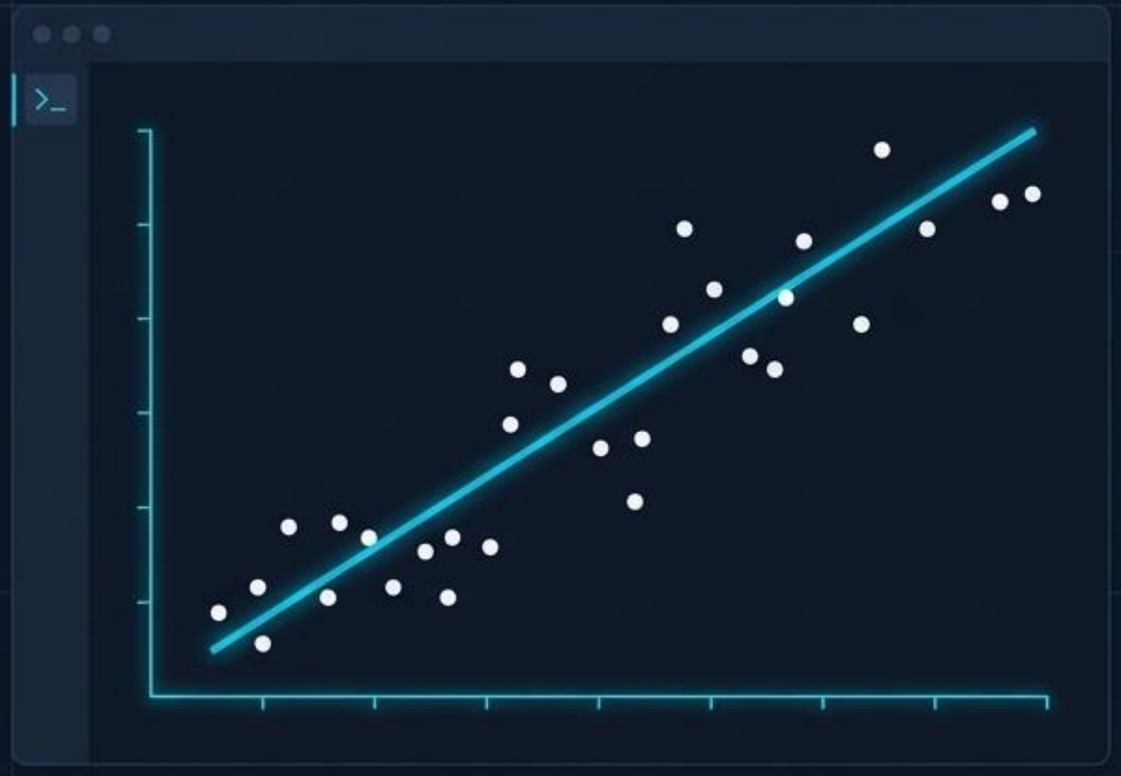

02

상관계수 (Correlation Coefficient)

Key Focus: 변수 간 연관성 분석 및 순위 척도 활용

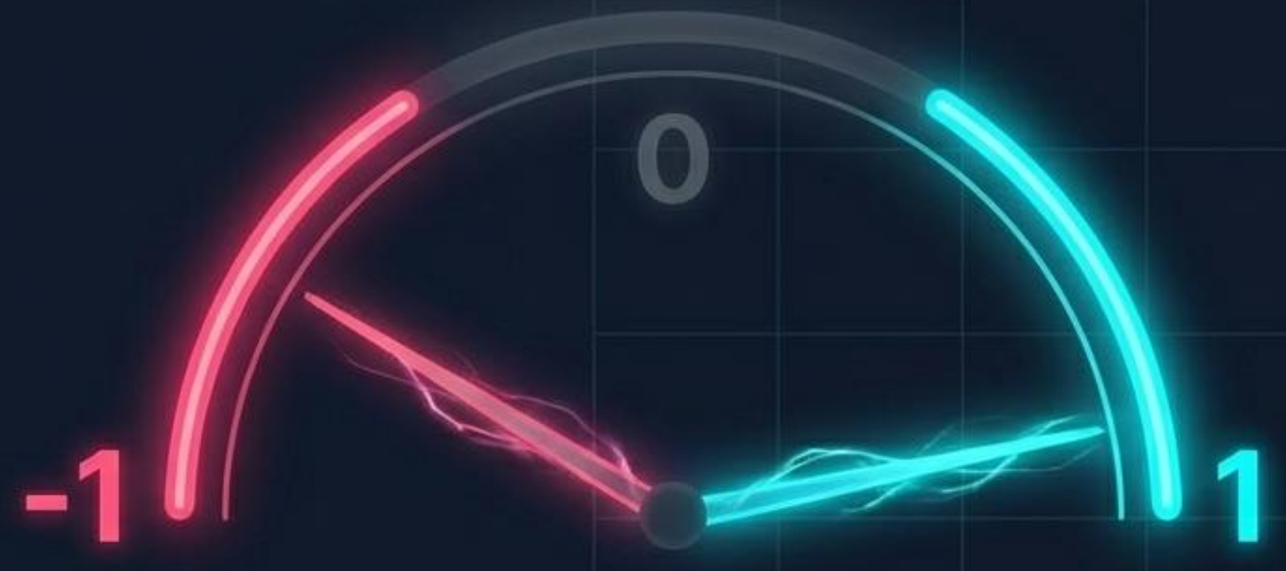

상관계수 개념

- 두 연속형 변수(열) 간의 연관성에 대한 측도임
- 연관된 정도를 나타낼 뿐, 인과관계를 의미하지는 않음
- Pandas Keyword: `corr`

값의 범위

- 양수**(+)**: 양의 상관관계 (비례)
- 음수**(-)**: 음의 상관관계 (부적 상관, 반비례)

피어슨 (Pearson) 상관계수

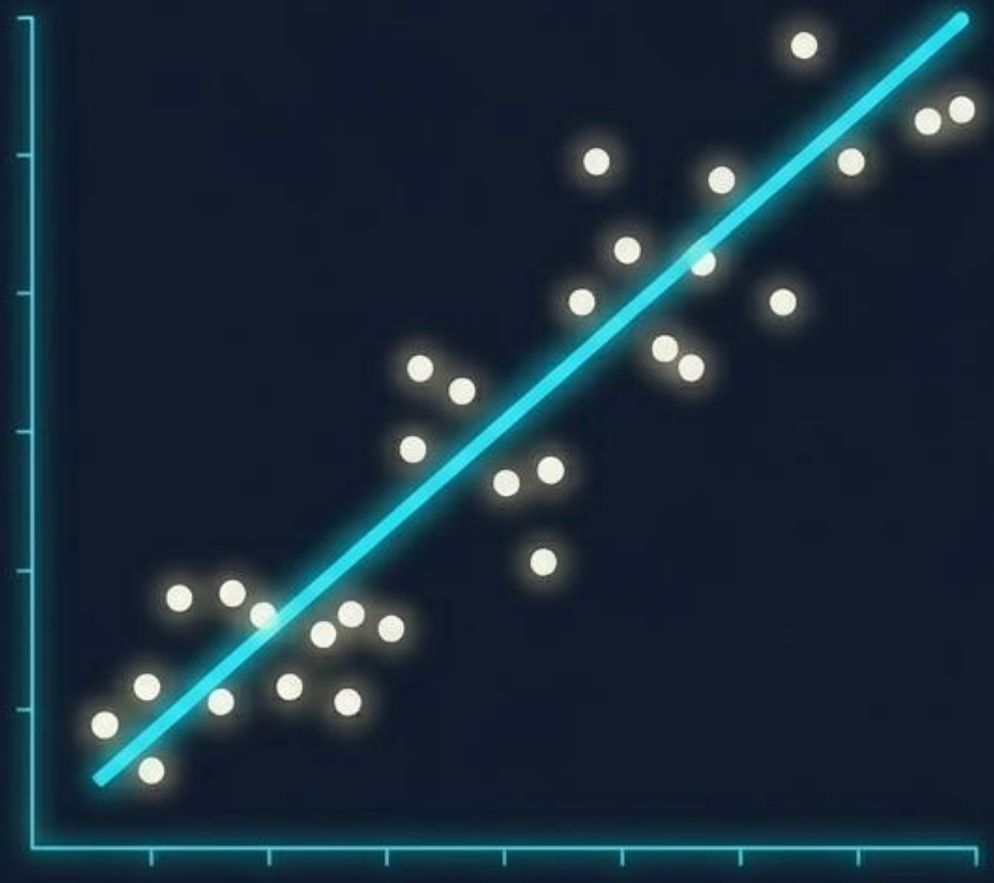

피어슨 (Pearson) 상관계수

- 가장 널리 활용되는 대표적인 상관계수임
- 두 변수 간의 선형적인 관계 (Linearity) 존재 여부를 판단함

해석 주의사항 ⚠

- 계수가 0에 가깝더라도 선형적 관계가 낮을 뿐임
- 서로 유의미한 관계가 전혀 없다는 것을 의미하지는 않음

API Reference: DataFrame.corr()

```
DataFrame.corr(method='pearson', min_periods=1)
```

상관계수 산출 방식 지정. 'pearson' (기본값), 'spearman', 'kendall' 설정 가능.

유효한 결과를 얻기 위한 최소 관측치 수 지정. 현재 피어슨, 스피어만 방식에서만 적용됨.